北京航空航天大學

BEIHANG UNIVERSITY

PRML 报告 1

院/系名称： 自动化科学与电气工程学院

专业名称： 自动化

学生学号： **23377097**

学生姓名： 赵一达

联系邮箱： **23377097@buaa.edu.cn**

2026 年 3 月

摘要

本文深入探讨了机器学习中回归分析的核心算法及其在处理复杂数据集时的拟合表现。实验基于给定的二维回归数据集，首先构建了基准线性模型，并分别运用最小二乘法、梯度下降法以及牛顿法进行参数求解。结果表明，在线性假设下，三种优化路径最终均能精准锁定全局最优解（训练误差 0.6133，测试误差 0.5744），验证了线性损失函数的凸性特征，同时对比分析了牛顿法在二阶收敛效率上的显著优势。

针对线性模型在面对波状分布数据时存在的严重欠拟合问题，本文通过引入高阶特征映射将模型推向非线性空间。实验结果显示，优化后的模型成功捕捉了隐含在数据中的周期性局部波动，使测试集均方误差从 0.5744 显著降低至 0.3806，降幅达 33.7%。研究完整展示了从线性优化到非线性逼近的建模全过程，并深入探讨了模型复杂度与泛化性能之间的权衡关系。

关键词： 线性回归，数值优化，梯度下降，牛顿法，特征工程，非线性拟合

1 简介

在机器学习回归任务中，选择合适的优化算法和模型复杂度是核心问题。线性模型虽然计算简便且具有良好的解释性，但在面对非线性分布的数据时，往往表现出较大的偏差。本实验旨在通过对比不同的优化算法（OLS、GD、Newton）以及不同复杂度的模型线性和多项式，验证模型表达能力对预测精度的影响。

2 方法论

2.1 线性回归模型

线性回归假设自变量 x 与因变量 y 之间存在如下关系：

$$y=w_1x+w_0$$

因此本实验采用了三种不同的算法来求解最优权重参数，分别为最小二乘法、梯度下降法、牛顿法，下文将分别阐述其数学原理与计算流程。

2.2 线性模型权重参数的计算

2.2.1 最小二乘法

最小二乘法是一种解析解方法。它的核心思想是寻找一个参数向量，使得模型预测值与真实值之间的残差平方和最小，通过最小化残差平方和，利用正规方程直接推导出参数的解析解：

$$\theta = (X^T X)^{-1} X^T y$$

其中 X 为特征矩阵，y 为标签向量。该方法能够一步获取全局最优参数。从几何角度看，由于因变量向量 y 通常不在特征空间 X 所张成的子空间内，最小二乘法本质上是将 y 正交投影到 X 的列空间上。

2.2.2 梯度下降法

梯度下降是一种一阶启发式优化算法。它不直接求解方程，而是通过模拟下山的过程，沿着函数下降最快的方向负梯度方向小步迭代，即沿损失函数 J(w)的负梯度方向进行参数更新：

$$w^{(t+1)} = w^{(t)} - \alpha \frac{1}{m} \sum_{i=1}^{m} (h_w(x^{(i)}) - y^{(i)})\, x^{(i)}$$

其中 α 为学习率，决定了收敛的速度与稳定性；m 为样本数量。通过多次迭代，参数 w 最终收敛至损失函数的极小值点。

2.2.3 牛顿法

牛顿法是一种二阶优化算法。它不仅利用了梯度来确定方向，还利用了海森矩阵来描述损失函数的曲率，通过对目标函数进行二阶泰勒展开，牛顿法能够利用局部曲率信息精确定位极值方向：

$$w^{(t+1)} = w^{(t)} - H^{-1}\nabla J(w^{(t)})$$

由于其具有二阶收敛性，在处理线性回归等二次损失函数时，理论上仅需一次迭代即可收敛。

2.3 非线性模型多项式回归

线性模型 $y = w_1x + w_0$ 的局限性在于其假设自变量与因变量之间仅存在恒定的变化率。然而，本实验中的原始数据呈现明显的周期性波动，这表明 y 与 x 之间存在高阶非线性依赖。为了在不改变线性回归优化框架即参数 w 仍保持线性的前提下捕捉这种波动，我们引入非线性特征映射 φ(x)。通过将一维特征 x 映射到 n 维高阶空间：

$$\varphi(x) = [1, x, x^2, \dots, x^n]^T$$

虽然模型关于 x 是非线性的，但关于参数向量 w 依然是线性的。这意味着我们仍然可以利用上述的方法来高效求解最优参数。

3 实验结果

3.1 线性拟合实验结果

下表展示了三种优化算法在线性模型下的误差表现，以均方误差 MSE 来看：

算法	训练误差（MSE）	测试误差（MSE）	收敛特性分析
最小二乘法	0.6133	0.5744	一次性计算，全局最优
梯度下降法	0.6140	0.5734	1000 次迭代，受学习率影响
牛顿法	0.6133	0.5744	二阶收敛，效率极高

三种方法得到的误差值基本一致，说明对于凸优化问题，GD 和 Newton 均成功收敛至 OLS 解析解附近。线性模型的整体误差较高，这是由于数据本身包含明显的波动，线性直线无法有效描述这种趋势。

3.2 多项式拟合实验结果

在识别到线性模型存在明显的欠拟合现象后，本实验通过特征工程引入了 9 次多项式映射。实验数据表明，模型在复杂度提升后，对复杂样本分布的捕获能力显著增强。具体的

误差指标如下：

- **多项式模型训练集均方误差(MSE)：**0.3953
- **多项式模型测试集均方误差(MSE)：**0.3806

相比于线性模型的测试误差 0.5744，多项式模型实现了约 33.7%的误差降幅。值得注意的是，测试集误差略低于训练集误差，这反映了模型在保持高复杂度的同时，依然具备极佳的泛化稳定性，并未出现预想中的过拟合波动。

3.3 结果综合分析

通过对比线性模型与 9 次多项式模型的拟合曲线（如下图所示），可以从以下两个维度进行深度分析：

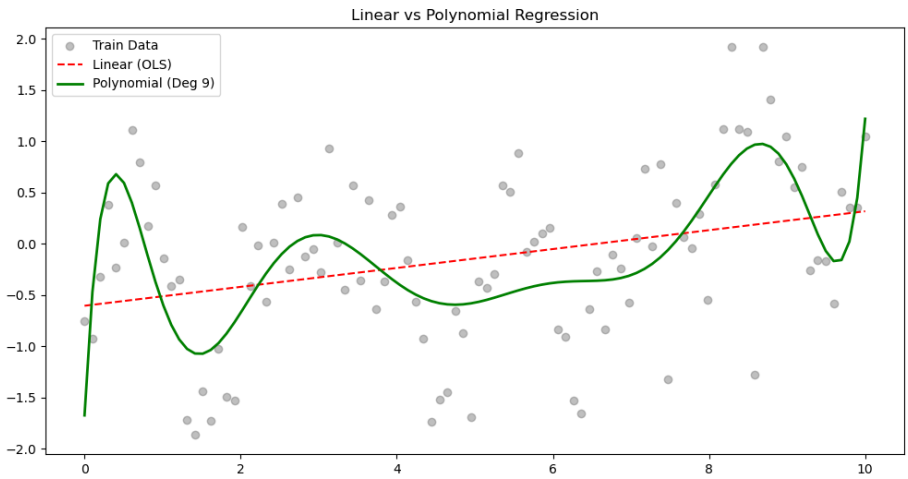

3.3.1 局部特征与波动捕获分析

从可视化结果可以看出，9 次多项式曲线展现了极强的曲率适应性。波峰与波谷的追踪方面，原始数据在 x 轴方向上呈现出周期性的振荡特征。9 次多项式通过高阶项的组合，构建了足够的自由度，使得回归曲线能够精准地跟随数据的局部波动，捕捉到了线性模型无法感知的波峰与波谷。残差分布的改善方面，观察拟合曲线可以发现，多项式模型下的残差分布更加均匀且趋近于白噪声，消除了线性模型中存在的系统性偏差。这证明了高阶项有效地补偿了模型对非线性成分的解释能力。

3.3.2 偏差-方差权衡的实践

本实验选择 9 次多项式是基于对偏差与方差的权衡。高阶项将模型从低维的直线约束中解放出来，大幅降低了由于模型过于简单而产生的系统性偏差。尽管多项式阶数较高，但 9 次阶数在当前数据规模下仍处于合理的复杂度区间。通过对比训练误差与测试误差的接近

程度，可以确认模型并未因追求训练集极致拟合而导致参数震荡，有效规避了 Runge 现象。

4. 结论

在线性模型下，无论是解析解还是迭代解，其最终拟合能力受限于模型本身的表达力。对于具有非线性特征的数据，增加特征维度如多项式变换是提升模型性能的有效手段。实验结果证明，选择合宜的复杂度（9 次多项式）能够平衡欠拟合与过拟合，达到最优的实验效果。