北京航空航天大學

BEIHANG UNIVERSITY

PRML 报告 2

院/系名称： 自动化科学与电气工程学院

专业名称： 自动化

学生学号： **23377097**

学生姓名： 赵一达

联系邮箱： **23377097@buaa.edu.cn**

2026 年 4 月

摘要

本文针对三维空间中呈非线性交织结构的两类数据（3D Make-Moons），系统比较了决策树、AdaBoost 结合决策树以及三种不同核函数的支持向量机（SVM）的分类性能。实验基于生成的三维数据集，共包含 1000 个训练样本与 500 个测试样本。结果表明，RBF 核 SVM 在该任务中表现最优，测试准确率可达 98%以上；决策树次之；线性 SVM 表现最差。本文进一步从模型复杂度、数据流形结构、核函数特性等角度分析了各算法性能差异的原因，验证了对于具有复杂局部曲率与非线性边界的分类问题，具有局部敏感性的核方法具有显著优势。

关键词： 非线性分类，支持向量机，决策树，AdaBoost，核方法，流形学习

1 简介

在机器学习分类任务中，数据分布的拓扑结构对模型选择具有决定性影响。线性模型假设类别之间可通过超平面分离，然而现实数据往往呈现嵌套、弯曲或流形结构。例如，常见的二维月牙形数据（make-moons）及其三维扩展版本，便是典型的非线性可分问题。本实验使用三维“月牙形”交织数据集，模拟真实场景中常见的非线性分类问题。通过比较决策树、AdaBoost +决策树、以及三种核函数的 SVM（线性核、多项式核、RBF 核），旨在回答以下核心问题：对于具有局部曲率变化和复杂边界的分类任务，何种算法具有更强的拟合与泛化能力？不同算法的内在机制如何解释其性能差异？在实际应用中，如何根据数据特点合理选择分类模型？

2 方法论

2.1 数据生成与预处理

本文采用标准三维月牙形数据生成函数 make_moons_3d。该函数基于二维正弦曲线构造三维流形，并通过偏移与噪声生成两类数据。生成公式如下：

对于第一类：

$$x = 1.5\cos(t), \quad y = \sin(t), \quad z = \sin(2t)$$

对于第二类：

$$x = -x, \quad y = y - 1, \quad z = -z$$

并添加高斯噪声 $\mathcal{N}$（0，σ^2），其中 $\sigma = 0.2$。

训练集包含 1000 个样本，测试集包含 500 个样本（每类 250 个）。该数据集的类别边界在三维空间中呈交织状，无法通过单一超平面分离。从几何角度看，两类数据分布在两个相互缠绕的曲面流形上，具有显著的局部曲率变化。

2.2 分类算法

2.2.1 决策树

决策树通过递归地选择最优特征与阈值，将特征空间划分为若干轴对齐的矩形区域。其决策边界呈分段常数形式，具有较强的非线性表达能力。然而，由于其划分方式与坐标轴平行，决策树在处理斜向或弯曲边界时往往需要大量深度，容易产生过拟合。

2.2.2 AdaBoost +决策树

AdaBoost（Adaptive Boosting）是一种集成学习方法，通过迭代训练多个弱分类器（此处为

深度为 1 的决策树桩），并依据上一轮分类误差调整样本权重。最终分类结果为弱分类器的加权投票。该方法能够提升弱模型的整体表达能力，但对噪声敏感，且收敛速度较慢。

2.2.3 支持向量机（SVM）

SVM 旨在寻找最大化分类间隔的超平面。对于非线性问题，通过核函数 kappa(x, x') = $(x)^T$ (x') 将数据隐式映射到高维特征空间。本文选用三种核函数：

①线性核：$\kappa(x,x')=x^Tx'$，适用于线性可分数据。

②多项式核：$\kappa(x,x')=(x^Tx'+c)^d$，其中 d=3，可捕捉一定程度的非线性交互。

③RBF 核：$\kappa(x,x')=\exp(-\gamma\|x-x'\|^2)$，具有局部敏感性，可近似任意非线性函数。

3 实验结果

3.1 分类准确率对比

下表展示了各算法在测试集上的分类准确率：

算法	测试准确率
Decision Tree	92.8%
AdaBoost + Decision Tree	88.4%
SVM (Linear)	66.2%
SVM (Polynomial, degree=3)	86.6%
SVM (RBF)	98.6%

3.2 结果综合分析

3.2.1 最优性能：SVM (RBF)

RBF 核 SVM 在所有算法中表现最优。其优势首先源于局部敏感性，RBF 核仅关注样本间局部相似度，能够拟合高度弯曲的流形边界。对于月牙形数据，类别边界在局部区域内近似线性，RBF 核通过局部加权实现精确拟合；其次是无限维映射，RBF 核对应无穷维特征空间，理论上可分离任意复杂拓扑结构的数据，无需显式构造高阶特征；最后是正则化控制，通过参数 C（惩罚系数） 与 gamma（核宽度） 可有效平衡模型复杂度与泛化能力，避免过拟合。

3.2.2 次优性能：决策树

决策树能够通过轴对齐分割逼近复杂的非线性边界，尤其在数据分布具有块状聚集特征时表现良好。然而其边界呈锯齿状，易受噪声扰动。尽管如此，在 3D 月牙数据中，决策树仍能捕捉到主要的空间分离结构。其准确率较高的原因在于：数据在三维空间中存在明显的区域聚集性，树模型可通过多层划分有效分离两类。

3.2.3 中等性能：AdaBoost 与 SVM (Polynomial)

1. AdaBoost：由于基学习器为决策树桩，每棵树仅依赖单一特征进行划分，难以协同利用三维空间中的多个维度。虽然通过多轮加权可逐步逼近复杂边界，但对噪声较敏感，收敛速度慢。此外，AdaBoost 在数据重叠区域容易放大噪声点的权重，导致泛化性能下降。

2. SVM (Polynomial)：多项式核通过特征组合生成高阶项（如 x^2, xy, z^3），能够拟合一定程度的非线性。但对于该数据中复杂的周期性弯曲，低阶多项式表达能力有限，表现逊于 RBF。提高多项式阶数虽可增强表达能力，但会显著增加计算复杂度并引入过拟合风险。

3.2.4 最差性能：SVM (Linear)

线性 SVM 的决策边界为超平面，而 3D 月牙数据的两类在空间中呈交织状，无法被任何平面线性分离。因此其准确率仅略高于随机猜测（约 66%），验证了该任务本质上的非线性可分性。这一结果也强调了在模型选择之前进行数据可视化或非线性检测的重要性。

3.3 偏差-方差分析

从偏差-方差分解的角度分析各模型：

模型	偏差	方差	说 明
RBF SVM	低	低	核方法结合正则化，拟合能力强且稳定
决策树	低	高	深度足够时可拟合复杂边界，但易受噪声扰动
线性 SVM	高	低	模型过于简单，无法捕捉数据中的非线性结构
AdaBoost	中	中	逐步降低偏差，但可能放大噪声点的方差

这一分析进一步解释了为何 RBF SVM 在该任务中表现最佳：它能够在保持低偏差的同时，通过正则化有效控制方差。

4 结论与模型选择建议

本文在三维月牙形非线性数据集上系统比较了多种分类算法。实验结果表明：

1. 最优模型：对于具有复杂流形结构的数据，具有局部敏感性的 RBF 核 SVM 表现最

佳，能够精确拟合非线性边界，且泛化能力强。

2. 次优模型：决策树作为单一模型，具有较好的非线性表达能力，但易受噪声影响，需配合剪枝或集成方法提升稳定性。

3. 失效模型：线性模型完全无法处理此类交织数据，验证了模型复杂度与数据分布匹配的重要性。

4. 集成学习局限：AdaBoost 在弱基学习器下性能受限，需配合更强的基模型或适当调参，如使用深度较大的决策树作为基学习器。

模型选择建议：

1. 当数据边界高度弯曲且局部特征显著时，RBF SVM 是稳健且高效的首选。

2. 当可解释性或计算效率更为重要时，可考虑决策树或线性模型加核化特征映射。

3. 当数据规模较大且特征维度较高时，集成方法（如随机森林、梯度提升）往往优于单一决策树。

4. 在实际应用中，应优先通过可视化或流形学习方法（如 t-SNE、UMAP）评估数据的非线性程度，再选择合适模型。

综上所述，模型的选择应充分考虑数据分布的结构特征与任务需求。对于非线性分类问题，核方法与树模型具有明显优势，而线性模型需谨慎使用。未来的工作可进一步探索深度学习模型在该类流形分类任务中的表现，以及自适应核学习方法的应用。