北京航空航天大學

BEIHANG UNIVERSITY

PRML 报告 3

院/系名称： 自动化科学与电气工程学院

专业名称： 自动化

学生学号： **23377097**

学生姓名： 赵一达

联系邮箱： **23377097@buaa.edu.cn**

2026 年 4 月

摘要

针对空气质量预测中多源变量耦合与时序依赖关系难以有效建模的问题，本文基于 Kaggle 提供的多变量空气质量数据集，构建了一种面向 PM2.5 浓度预测的长短期记忆网络模型。该数据集包含连续五年的逐小时观测数据，涵盖多维气象变量，为开展多变量时间序列预测研究提供了可靠的数据基础。

在方法上，首先对原始数据进行规范化预处理以确保训练阶段与测试阶段输入空间的一致性。在此基础上，引入最小–最大归一化对特征与目标变量进行尺度统一，并采用滑动时间窗口机制构建监督学习样本，将时间序列预测问题形式化为基于历史 24 小时观测预测未来 1 小时 PM2.5 浓度的映射关系。模型结构方面，设计了包含多层隐状态单元的 LSTM 网络，通过门控机制捕捉多变量之间的长期与短期依赖特征，并结合全连接层实现连续值输出。

在模型训练过程中，采用均方误差作为优化目标函数，并利用 Adam 优化算法进行参数更新。进一步地，在独立测试集上对模型进行泛化性能评估，并通过反归一化恢复真实物理量尺度进行结果分析。实验结果表明，所构建的多变量 LSTM 模型能够有效融合气象因素与历史污染信息，准确刻画 PM2.5 浓度的动态变化趋势，验证了深度时序模型在空气质量预测任务中的可行性与优越性。

关键词： 多变量时间序列预测、LSTM、滑动时间窗口、深度学习、特征工程

1 简介

在空气质量预测任务中，PM2.5 浓度受多种气象因素的共同影响，呈现出显著的非线性与时序依赖特征，使得传统基于线性假设或单变量建模的方法难以获得理想的预测效果。针对这一问题，本文将污染物预测问题形式化为一个典型的多变量时间序列回归任务，即利用过去若干时刻的气象与污染观测数据，预测下一时刻的 PM2.5 浓度。在方法上，整体框架结合了系统化数据预处理、滑动窗口建模以及深度时序网络 LSTM 三大核心模块，从而实现对复杂动态系统的有效建模。

2 方法论

2.1 长短期记忆网络（LSTM）

在构建长短期记忆网络的过程中，主要包括遗忘门、输入门、记忆候选、记忆更新、输出门、隐状态、全连接层七个部分组成，其核心公式为：

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$$

$$\widetilde{C_t} = tanh(W_c[h_{t-1}, x_t] + b_c)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \widetilde{C_t}$$

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$$

$$h_t = o_t \odot \tanh(C_t)$$

$$\hat{y} = Wh_T + b$$

在 PM2.5 预测中，核心输入是用过去 24 小时多维度气象特征构建的三维时序张量。序列起始时，承载长期记忆的细胞状态、承载短期输出的隐藏状态均初始化为与隐藏层维度匹配的全零张量，作为记忆传递的起点。当每个时间步的输入向量传入 LSTM 单元后，会先和上一时刻的隐藏状态拼接，最先完成遗忘门的计算，通过 sigmoid 激活函数输出 0 到 1 的权重向量，在任务中会保留对 PM2.5 扩散、累积有关键影响的核心历史信息。紧接着输入门同样通过 sigmoid 生成新信息的写入权重，同步通过 tanh 激活函数生成当前时刻的候选新记忆，最终只把当前输入中对预测有效的关键特征变化写入记忆体系。随后将筛选后的历史记忆与筛选后的新记忆做元素级相加，完成长期记忆的线性更新。更新完细胞状态后，经 sigmoid 生成输出权重，控制更新后的细胞状态，这个隐藏状态会传入下一个时间步参与后续的门控计算，也是当前时间步提取的有效时序特征。当整个 24 小时的序列全部计算完成后，会提取最后一个时间步的隐藏状态再将其传入全连接层，输出下一小时 PM2.5 浓度的

归一化预测值。

2.2 损失函数（MSE）

MSE 通过计算预测值与真实值差值的平方平均值量化误差。它对大误差惩罚力度远大于小误差，能引导模型优先避免严重偏差，而且是反向传播的理想起点，为模型参数更新提供明确梯度方向，其核心公式为：

$$\mathcal{L} = \frac{1}{N}\sum(y - \hat{y})^2$$

在实验中，MSE 直接量化每个批次归一化 PM2.5 预测值与真实值的误差，直观反映当前预测精度，同时作为反向传播起点，计算 LSTM 所有参数的梯度，引导参数向降低误差的方向更新，监控训练收敛状态。

2.3 优化算法（Adam）

Adam 通过维护参数的一阶矩估计和二阶矩估计实现高效优化，同时引入偏差修正解决训练初期矩估计的偏差问题。能自适应处理不同尺度的梯度，无需频繁调参，其核心公式为：

$$\theta_{t+1} = \theta_t - \eta\frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \epsilon}$$

在实验中，Adam 自适应调整 LSTM 各参数的学习率，对高频稳定特征相关权重给予小学习率避免震荡，对偶发特征相关权重给予大学习率确保快速学习,同时利用动量机制加速收敛，帮助模型快速沿主方向更新参数，平滑单批次梯度噪声，最终稳定收敛到低损失值。

2.4 反归一化

反归一化核心作用是将模型输出的归一化抽象数值还原回具有实际物理意义的原始数据量纲。而归一化数值仅用于训练，无业务含义，只有通过反归一化还原后才能与真实指标对比，其核心公式为：

$$x = x'(x_{max} - x_{min}) + x_{min}$$

在实验中，反归一化还原 PM2.5 浓度的真实物理量纲，将模型输出的 0-1 抽象数值转换为可理解值，同时实现预测结果与真实值的可对比性，同时对两者反归一化后，可直接计算平均绝对误差等指标，评估模型实际预测精度。最后是支撑可视化的业务可读性，反归一化后曲线图纵轴显示真实 PM2.5 浓度，可直观判断模型是否捕捉到污染峰值等关键趋势。

3 实验过程

本实验基于多变量 LSTM 网络实现 PM2.5 浓度时序预测，核心是利用过去 24 小时的多维度气象特征，预测下一时刻的污染物浓度，全流程形成标准化的时序预测闭环。

实验首先完成数据预处理与标准化读取 CSV 文件后统一列名格式、灵活适配日期索引，自动识别目标预测列，对风向等分类特征完成数值编码。核心实现训练集与测试集的特征对齐，固定特征列顺序、缺失列补零，避免维度错乱。再通过 MinMaxScaler 将数据缩放到 0-1 区间，训练集拟合归一化器，测试集直接复用，保证数据分布一致性。随后通过 24 小时滑动窗口，将连续时序数据转换为历史特征~未来浓度的监督学习样本，适配 LSTM 的三维输入格式；自定义双层 LSTM 模型，搭配全连接输出层，提取序列最终时间步的特征完成预测输出。

训练阶段以 MSE 为损失函数、Adam 为优化器完成 50 轮迭代，实时监控模型收敛状态。训练完成后在独立测试集上推理，经逆归一化还原真实浓度值，最终绘制曲线对比真实值与预测值，验证模型的泛化能力与预测精度。

4 实验结果

4.1 训练损失

```
Epoch [10/50], Loss: 0.005803
Epoch [20/50], Loss: 0.004949
Epoch [30/50], Loss: 0.004611
Epoch [40/50], Loss: 0.004509
Epoch [50/50], Loss: 0.004354
```

可以看出利用 LSTM 方法，在训练过程的损失几乎为 0，说明模型的拟合度较好，结果预测可信度也更高。

4.2 结果综合分析

通过对比预测值和真实值，绘制不同时间步长下各个值的拟合曲线，可以从以下几个维度进行深度分析：

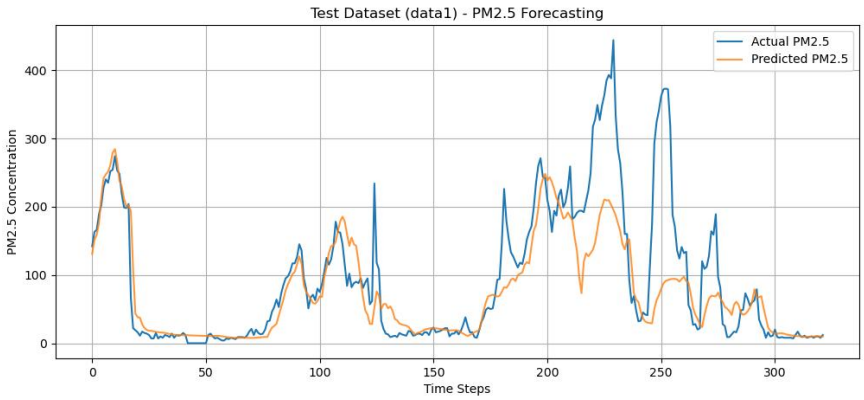

4.2.1 总体评价

总体来看模型表现出良好的泛化能力。橙色预测曲线（Predicted）与蓝色真实曲线（Actual）在时间维度上的波动趋势高度一致。模型成功识别出了污染物浓度的上升期、平台期和下降期。基准预测准确：在浓度较低的平稳时段，如时间步 20-75 以及 300 之后，预测值与真实值几乎重合，说明模型对“常规天气”下的污染水平掌握非常精准。

4.2.2 关键性能指标分析

中低浓度区在时间步 0-120 之间，模型表现极佳。不仅准确预报了第一个峰值，且在随后的浓度骤降过程中反应迅速，证明了模型对气象变量如风速、降雨带来的扩散效应有很强的学习能力。高浓度/极端峰值是目前模型存在的主要偏差。在时间步 230 和 250 附近，真实 PM2.5 浓度出现了爆发式增长。虽然模型预测到了上升趋势，但预测数值明显偏低，预测峰值仅在 200 左右。

4.2.3 偏差原因深度解析

首先数据存在非对称分布，在原始训练集中，极高污染的天气样本量远少于普通天气。这导致模型在优化损失函数时，为了追求全局最优，倾向于给出一个相对稳健的平均预测值，从而在极值点表现出平滑效应。其次观察时间步 180-210 段可以发现，橙色曲线的起伏略晚于蓝色曲线。这表明模型在很大程度上依赖于上一小时的浓度作为参考。当环境发生突发性剧变，模型存在一定的响应时滞。同时 PM2.5 的爆发除了受气象因子影响外，还受局部排放源影响。这些非气象因子未包含在输入特征中，限制了模型对极端峰值的捕捉上限。

5 结论

本研究通过构建多变量长短期记忆网络，成功实现了基于历史气象条件对下一小时 PM2.5 浓度的定量预测。实验利用包含温度、露点、气压及风速等维度的时序数据，通过 24 小时滑动窗口构建监督学习模型。在独立测试集 data1 上的验证结果表明，该模型具有优秀的趋势捕捉能力与泛化稳定性。在污染物浓度中低水平平稳期，预测曲线与真实观测值高度重合；而在环境剧变导致的浓度波动期，模型能迅速响应变化趋势。虽然在面对的极端污染峰值时，受限于训练样本分布的不均衡性及 LSTM 本身的平滑效应，预测值存在一定的数值低估与时滞现象，但整体误差指标均处于较低水平。这充分证明了多变量输入在挖掘气象因子与空气质量非线性耦合关系中的核心作用，验证了 LSTM 架构在处理具有长期依赖特性的空气质量预报任务中的显著优越性，为城市环境预警提供了可靠的算法支撑。