



北京航空航天大学
B E I H A N G U N I V E R S I T Y

PRML 报告 4

院/系名称： 自动化科学与电气工程学院

专业名称： 自动化

学生学号： 23377097

学生姓名： 赵一达

联系邮箱： 23377097@buaa.edu.cn

2026 年 5 月

摘要

本文从零实现了一种轻量化 Transformer 模型，并以序列反转任务为实验平台，系统比较了不同位置编码策略及不同神经网络架构在序列建模问题中的性能差异。实验构建了包含 Transformer 三种位置编码、基于长短期记忆网络的循环神经网络以及基于一维卷积的卷积神经网络共五类模型，通过统一的数据集规模、训练参数与评估标准，对模型的收敛速度、计算效率、参数规模及序列生成能力进行了综合分析。

在模型设计方面，Transformer 部分采用手写实现的编码器解码器结构，包括多头自注意力机制、前馈神经网络、层归一化以及掩码机制，并分别研究无位置编码、固定正弦位置编码与可学习位置编码对序列建模性能的影响。同时，为验证 Transformer 在序列任务中的有效性，本文进一步构建基于 LSTM 的 Seq2Seq 模型以及基于一维卷积的 CNNSeq2Seq 模型作为横向对比基线。实验过程中采用交叉熵损失函数与 AdamW 优化器进行训练，并通过精确序列匹配准确率对模型生成结果进行评估。

实验结果表明，Transformer 模型在序列生成任务中具有较强的全局依赖建模能力，其中引入位置编码后模型性能得到显著提升，相比之下，无位置编码的 Transformer 难以准确学习序列顺序信息。进一步分析发现，可学习位置编码在小规模数据集条件下表现出更高的适应性，而正弦位置编码则具有更好的稳定性与泛化能力。与此同时，LSTM 模型在短序列任务中仍具有一定竞争力，但在并行计算效率方面明显低于 Transformer，CNN 模型虽然训练速度较快，但由于局部感受野限制，其长距离依赖建模能力相对较弱。本文还通过注意力热力图对 Transformer 解码阶段的跨注意力分布进行了可视化分析，从而验证了注意力机制在序列映射过程中的有效对齐能力。

总体而言，本文通过轻量化实验框架验证了 Transformer 在序列建模任务中的优势，并系统分析了位置编码机制对模型性能的影响，为后续基于 Transformer 的大规模序列学习研究与结构优化提供了实验依据与理论参考。

关键词： Transformer、Attention Mechanism、Sequence-to-Sequence Learning、Positional Encoding、Long Short-Term Memory、Convolutional Neural Network、序列反转任务、模型对比实验

1 简介

本文从零实现了轻量化 Transformer 序列生成模型，并以序列反转任务为实验对象，对不同位置编码策略及不同神经网络结构进行了系统对比研究。实验分别构建了无位置编码、正弦位置编码和可学习位置编码三类 Transformer 模型，同时引入基于 LSTM 的 RNN 模型与 CNN 模型作为对比基线。通过统一训练参数与评估标准，对模型的训练损失、计算效率及序列生成准确率进行了综合分析，验证了 Transformer 在序列建模任务中的优越性。

2 实验方法

2.1 Transformer 模型整体架构

TransformerSeq2Seq (主模型)

- src_embedding & tgt_embedding (TokenPositionEmbedding)
- encoder_layers (nn.ModuleList)
 - **EncoderLayer** × 2
 - self_attn (MultiHeadAttention)
 - ffn (PositionwiseFeedForward)
 - norm1 & norm2 (nn.LayerNorm)
- decoder_layers (nn.ModuleList)
 - **DecoderLayer** × 2
 - self_attn (MultiHeadAttention, 带因果掩码 Causal Mask)
 - cross_attn (MultiHeadAttention, 引入编码器 Memory)
 - ffn (PositionwiseFeedForward)
 - norm1 & norm2 & norm3 (nn.LayerNorm)
- output_proj (nn.Linear)

2.2 核心模块数学原理及公式

2.2.1 缩放点积注意力

注意力机制通过计算查询与键的相似度，对值进行加权求和。为了防止向量维度 d_k 过大导致点积结果过大、Softmax 函数进入饱和区从而梯度消失，引入了缩放因子 $\sqrt{d_k}$ 。

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}} + M)V$$

其中 Q 为查询矩阵, K , V 为键、值矩阵, M 为掩码矩阵。若某位置被掩码, 则 M 矩阵对应的 i 、 j 位置的值会被设置为 -10^9 , 经 Softmax 后其对应的注意力权重趋近于 0。

2.2.2 多头注意力机制

多头注意力机制允许模型在不同的表示子空间中共同关注来自不同位置的信息。本代码将通道维度 d_{model} 均匀拆分为 h 个头, 独立计算注意力后再进行拼接与线性投影。

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

其中映射矩阵 W_i^Q 、 W_i^K 、 W_i^V 的维度为 $d_{\text{model}} \times d_k$, 映射矩阵 W^O 的维度为 $d_{\text{model}} \times d_{\text{model}}$, 且满足 $d_k = d_{\text{model}}/h$ 。

2.2.3 正弦位置编码

由于注意力机制内部的矩阵乘法是置换不变的 (即对序列顺序不敏感), 因此必须引入位置编码以赋予模型感知序列绝对和相对位置的能力。正弦位置编码公式为:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

其中 pos 为 Token 在序列中的绝对位置索引, i 为特征维度的序号。该编码利用三角函数的周期性, 使得模型能更轻松地学习到相对位置关系。

2.2.4 逐位置前馈网络

在注意力层之后, 每个位置的 Token 独立且对称地通过一个双层全连接网络, 中间包含一次非线性激活, 用于引入非线性表达并进行特征转换。

$$FFN(x) = \max(0, xW_1 + b_1) W_2 + b_2$$

其中第一层全连接层将维度从 d_{model} 映射至 d_{ff} , 经 ReLU 激活后, 第二层再将其映射回 d_{model} 。

2.2.5 层归一化

为了稳定深层神经网络的激活值分布、加速模型收敛, 模型在每个子层 (Attention 和 FFN) 之后引入了层归一化。与 Batch Normalization 针对样本通道不同, Layer Normalization 是在单个样本内部的特征维度上计算均值和方差。

$$LN(x) = \frac{x - \mu}{\sqrt{\sigma^2 + \varepsilon}} \odot \gamma + \beta$$

其中给定的特征向量 x 属于 d_{model} , 其均值 μ 与方差 σ^2 分别为:

$$\mu = \frac{1}{d_{\text{model}}} \sum_{i=1}^{d_{\text{model}}} x_i, \sigma^2 = \frac{1}{d_{\text{model}}} \sum_{i=1}^{d_{\text{model}}} (x_i - \mu)^2$$

γ 和 β 为可学习的缩放与平移参数, ε 为防止分母为 0 的极小常数。

2.2.6 残差连接

为了避免网络加深时带来的梯度消失与退化问题, 每个子层 (Attention、FFN) 的输入与输出之间都采用了残差连接。代码中采用的是经典的 **Post-LN** 结构, 即先做计算, 再做残差, 最后归一化:

$$Output = LN(x + SubLayer(x))$$

其中 $SubLayer(x)$ 代表多头注意力或前馈网络的计算映射。

2.2.7 序列掩码机制

在 Transformer 中, 掩码机制主要起到两个核心作用, 首先是 **PaddingMask** 填充掩码, 针对输入序列中为了对齐批处理而补齐的 <PAD> 符号。代码通过生成布尔矩阵, 将所有 <PAD> 位置的注意力权重强制置为负无穷, 阻止模型对无意义的填充符号分配注意力。**CausalMask** 因果自回归掩码, 用于解码器的自注意力中。为了确保模型在预测当前位置的 Token 时, 不能偷看未来的信息。通过生成一个严格的下三角矩阵, 将未来位置的权重全部屏蔽:

$$M_{ij} = \begin{cases} 0, & i \geq j \\ -10^9, & i < j \end{cases}$$

2.2.8 交叉注意力机制

交叉注意力机制存在于解码器的中间层, 用于建立输出序列与输入源序列之间的语义对齐。它的数学结构与多头注意力完全一致, 但其输入向量的来源发生了本质改变。**Query (Q)** 来自解码器上一层的自注意力输出, 代表当前已生成的翻译文本状态。**Key (K)** 和 **Value (V)** 均来自编码器的最终输出 **Memory**, 代表源文本的全局上下文特征。这使得解码器在生成每个字符时, 都能在整个源序列中动态搜寻最相关的上下文线索。

2.3 实验数据及规模

本实验采用的是一种人工构造的合成序列数据集, 其核心任务为序列反转。数据集并非来源于真实语料, 而是通过随机生成整数序列构建, 用于验证不同序列模型对顺序依赖关系的学习能力。输入序列为 $X = [x_1, x_2, \dots, x_L]$ 。

①数据集与任务超参数:

超参数名称	含义说明	设定值
VOCAB_SIZE	词表大小 (含特殊 Token)	20
SEQ_LEN	基础序列长度	10
MAX_LEN	模型的最大序列承载长度	30

TRAIN_SAMPLES	训练集样本总数	1500
VAL_SAMPLES	验证集样本总数	300
TEST_SAMPLES	测试集样本总数	300
PAD_ID / BOS_ID / EOS_ID	特殊 Token 的 ID 映射	0/1/2

②Transformer 模型架构超参数：

超参数名称	含义说明	设定值
D_MODEL	词嵌入与隐藏层维度 d_{model}	64
N_HEADS	多头注意力的头数 h	4
D_K	注意力头的内部维度 d_k	16
D_FF	前馈网络隐藏层维度 d_{ff}	128
N_LAYERS	编码器与解码器的堆叠层数	2
DROPOUT	随机失活概率	0.1

③训练与优化超参数：


超参数名称	含义说明	设定值
BATCH_SIZE	单次批处理样本数	32
EPOCHS	完整迭代轮数	35
LEARNING_RATE	初始学习率 AdamW	$5e-4$
WEIGHT_DECAY	权重衰减系数 L2 正则化	$1e-4$
SEED	随机数种子确保实验可复现	42
Loss Function	损失函数类型	交叉熵损失忽略 PAD

本实验在保持模型隐藏层维度和层数一致的前提下，通过更改 `pe_type` 分别为 `none`、`sinusoidal`、`learned` 开展消融，并引入同等隐层维度的 RNN-LSTM 与 CNN-1D 作为架构对比基线。

3 实验结果

3.1 测试集准确率分析

下图展示了不同模型在测试集上的精确序列匹配准确率。从结果可以看出，Transformer-Sinusoidal、Transformer-Learned 以及 RNN-LSTM 三种模型均取得了接近 100% 的测试准确率，说明这些模型已经能够较好地学习输入序列与目标逆序序列之间的映射关系。




其中, Transformer-Sinusoidal 与 Transformer-Learned 模型均表现出极强的序列生成能力。这表明当 Transformer 引入位置编码机制后, 模型能够有效获取序列中的位置信息, 并通过自注意力机制建立输入与输出之间的全局依赖关系。在序列反转任务中, 模型需要准确识别输入 token 的顺序并完成逆序映射, 因此位置编码对模型性能具有决定性作用。相比之下, 不带位置编码的 Transformer-None 模型测试准确率几乎为零。虽然模型在训练过程中损失函数有所下降, 但由于缺少位置编码, 自注意力机制无法区分不同 token 的位置顺序, 因此模型无法真正学习序列反转规则。该结果进一步验证了位置编码是 Transformer 模型中的关键组成部分。

此外, RNN-LSTM 模型同样取得了较高准确率。这说明 LSTM 依靠循环结构与隐藏状态传播, 能够有效学习短序列中的时序依赖关系。在当前序列长度仅为 10 的条件下, LSTM 的记忆能力能够满足任务需求, 因此其性能接近 Transformer 模型。CNN-1D 模型的测试准确率约为 0.83, 明显低于 Transformer 与 LSTM。虽然卷积网络能够利用局部感受野提取邻域特征, 但其对长距离依赖关系的建模能力较弱, 因此在需要全局顺序映射的序列反转任务中存在一定局限性。

总体而言, 实验结果表明, 在序列建模任务中, Transformer 与 LSTM 均能够有效学习序列依赖关系, 而位置编码机制则是 Transformer 获得高性能的重要前提。

3.2 模型参数量与计算效率分析



结合训练损失曲线与模型训练耗时可以进一步分析不同模型的计算效率与收敛特性。从训练损失变化趋势可以看出，各模型在训练初期均表现出较快的损失下降速度，但不同模型的最终收敛能力存在明显差异。

Transformer-Learned 与 Transformer-Sinusoidal 模型在训练过程中均呈现稳定下降趋势，并最终达到较低损失值。这说明加入位置编码后，Transformer 能够有效学习序列间的映射关系。其中，可学习位置编码在训练初期收敛速度略快，而正弦位置编码在后期表现出更稳定的优化趋势。Transformer-None 的损失下降速度明显慢于其他 Transformer 模型，并且在训练后期仍保持较高损失值。这进一步说明缺少位置编码后，模型无法建立有效的时序依赖关系，因此即使训练轮数增加，其性能提升依然有限。

RNN-LSTM 模型在训练过程中同样表现出较好的收敛能力，其损失函数下降较快，并最终达到较低水平。这表明循环神经网络在短序列任务中仍具备较强的序列学习能力。然而，由于 LSTM 采用递归结构，其计算过程依赖时间步迭代，因此训练并行效率相对较低。CNN-1D 模型在训练初期损失迅速下降，并较快达到稳定状态。这是因为卷积结构具有较强并行计算能力，能够快速完成局部特征提取。然而，由于卷积感受野有限，其全局依赖建模能力不足，因此最终准确率仍低于 Transformer 与 LSTM。

总体来看，Transformer 在训练效率与模型性能之间取得了较好的平衡。其中，自注意力机制能够实现全局并行计算，相比传统 RNN 更适合大规模序列建模任务。同时，本实验所采用的轻量化 Transformer 结构通过降低隐藏层维度、减少编码层数量以及缩小前馈网络规模，有效降低了模型复杂度，使模型能够在普通 CPU 或轻量级硬件环境下完成训练任务。

3.3 Transformer 位置编码机制分析

位置编码是 Transformer 模型中的核心组成部分，其主要作用是向模型提供序列中的位置信息。由于自注意力机制本身不具备时序结构，因此模型必须依赖位置编码来区分不同

token 的顺序关系。为研究不同位置编码方式对模型性能的影响，本文分别构建了无位置编码、固定正弦位置编码以及可学习位置编码三种 Transformer 模型，并进行了系统对比分析。

3.3.1 无位置编码模型分析

实验结果表明，不带位置编码的 Transformer-None 模型几乎无法完成序列反转任务，其测试准确率接近于零。虽然训练损失在一定程度上有所下降，但模型始终无法学习有效的序列顺序映射关系。

造成这一现象的主要原因在于，自注意力机制本质上是一种集合级信息聚合方式，其仅关注 token 之间的相关性，而无法自动感知 token 在序列中的位置顺序。因此，在缺少位置编码时，相同 token 无论出现在序列的任何位置，其特征表示均保持一致，模型难以建立有效的时序关系。对于序列反转任务而言，模型需要精确识别输入序列的顺序结构并输出逆序结果，因此位置信息具有决定性作用。本实验结果进一步验证了位置编码在 Transformer 架构中的必要性。

3.3.2 正弦位置编码分析

正弦位置编码通过固定三角函数生成位置向量，并将其与 tokenembedding 相加，从而为模型提供序列顺序信息。该方法不需要额外训练参数，因此具有较好的稳定性与泛化能力。

实验结果表明，Transformer-Sinusoidal 模型在测试集上取得了接近 100% 的准确率，同时训练过程表现出较好的稳定性。这说明固定位置编码已经能够充分帮助模型学习序列反转任务中的顺序关系。此外，模型注意力权重主要集中于逆对角线区域，说明解码器在生成目标 token 时能够正确关注输入序列中的对应位置。这表明正弦位置编码能够有效辅助模型建立稳定的输入—输出映射关系。总体而言，正弦位置编码在当前实验中表现出了较好的稳定性与序列建模能力。

3.3.3 可学习位置编码分析

可学习位置编码通过参数化方式直接学习位置向量，使模型能够根据具体任务自动优化位置表示。实验结果表明，Transformer-Learned 同样取得了接近 100% 的测试准确率，并在训练初期表现出较快的损失下降速度。

相比固定正弦位置编码，可学习位置编码具有更强的灵活性与任务适应能力。在当前小规模数据集条件下，模型能够根据训练数据自动调整位置特征，从而提升序列建模效果。然而，从整体结果来看，Transformer-Learned 与 Transformer-Sinusoidal 的性能差异已经较小。这说明对于当前简单序列反转任务而言，两种位置编码方式均能够有效完成时序建模任务。总体来看，可学习位置编码更适用于需要高度任务适应性的场景，而正弦位置编码则具有更

好的稳定性与泛化能力。

4. 结论

本章基于序列反转任务，对 Transformer、RNN 与 CNN 三类序列模型进行了系统实验对比，并重点分析了位置编码机制对 Transformer 性能的影响。实验结果表明，加入位置编码后的 Transformer 模型能够有效学习序列顺序关系，并在测试集上取得接近 100% 的准确率；相比之下，无位置编码的 Transformer 几乎无法完成序列生成任务，说明位置编码是 Transformer 架构中的关键组成部分。

进一步实验发现，LSTM 模型在短序列任务中同样具有较强的时序建模能力，而 CNN 模型虽然具有较高计算效率，但由于缺乏全局依赖建模能力，其最终性能相对较低。此外，通过跨注意力热力图分析可以发现，Transformer 模型能够自动学习输入与输出之间的逆序对应关系，注意力权重主要集中于逆对角线区域，体现了自注意力机制良好的可解释性与全局建模能力。

综合实验结果可以看出，轻量化 Transformer 在保证较高序列生成性能的同时兼顾了较好的训练效率，为后续复杂序列学习任务中的 Transformer 结构优化与应用研究提供了有效实验基础。